Studi Ablasi RNN, LSTM, dan GRU dibandingkan ANN untuk Prediksi Trafik Seluler Taman Kota Parco Sempione

Tyodonrau
NIM 124400052
Teknik Telekomunikasi, ITERA
tyodonrau.124400052@student.itera.ac.id

Adryan Ari Nur Hakim P
NIM 124400026
Teknik Telekomunikasi, ITERA
email@student.itera.ac.id

Joan Felix Tampubolon
NIM 124400088
Teknik Telekomunikasi, ITERA
email@student.itera.ac.id

***Abstract*—Prediksi trafik seluler merupakan salah satu aspek penting dalam pengelolaan jaringan telekomunikasi karena pola penggunaan jaringan dapat berubah berdasarkan waktu dan lokasi. Penelitian ini bertujuan untuk membandingkan kinerja Artificial Neural Network (ANN), Recurrent Neural Network (RNN), Long Short-Term Memory (LSTM), dan Gated Recurrent Unit (GRU) dalam memprediksi trafik seluler di kawasan Taman Kota Parco Sempione, Milan, Italia. Data penelitian menggunakan dataset trafik seluler Kota Milan dari Telecom Italia, dengan fokus pada data wilayah yang mewakili kawasan Parco Sempione. Variabel target yang diprediksi adalah trafik internet (net) untuk satu jam berikutnya berdasarkan data historis selama 24 jam. Kinerja model dievaluasi menggunakan Mean Absolute Error (MAE), Root Mean Squared Error (RMSE), dan Mean Absolute Percentage Error (MAPE). Penelitian ini juga menerapkan studi ablasi untuk menganalisis pengaruh perubahan panjang jendela waktu, ukuran lapisan tersembunyi, jumlah lapisan, learning rate, kelompok fitur, dan fungsi loss terhadap kinerja prediksi. Setiap konfigurasi diuji menggunakan tiga seed untuk mengamati konsistensi hasil pelatihan. Konfigurasi terbaik ditentukan berdasarkan nilai MAE pada data validasi, kemudian dievaluasi menggunakan data pengujian. Selain itu, pengujian generalisasi dirancang untuk mengamati kemampuan model ketika diterapkan pada lokasi yang berbeda. Penelitian ini diharapkan dapat memberikan pemahaman mengenai perbandingan kinerja ANN, RNN, LSTM, dan GRU serta pengaruh konfigurasi model terhadap akurasi prediksi trafik seluler di kawasan Parco Sempione.**

Kata kunci: prediksi trafik seluler, Parco Sempione, ANN, RNN, LSTM, GRU, studi ablasi.

***Index Terms*—prediksi trafik seluler, RNN, LSTM, GRU, studi ablasi**

I. Pendahuluan

Peramalan trafik seluler per jam sangat krusial bagi operator telekomunikasi untuk mengoptimalkan alokasi sumber daya jaringan, menghemat konsumsi energi sel, dan mencegah terjadinya degradasi layanan (*congestion*). Karakteristik data trafik yang memiliki ketergantungan temporal yang kuat membuat model sekuensial seperti RNN, LSTM [1], dan GRU [2] lebih diunggulkan dibanding ANN konvensional karena kemampuannya dalam menangani memori urutan waktu. Untuk memahami sensitivitas tiap arsitektur terhadap perubahan parameter, studi ablasi penting dilakukan dengan cara mengisolasi dan mengubah satu faktor konfigurasi dalam satu waktu.

Kontribusi utama dari laporan ini adalah:

1) Mengevaluasi pengaruh lima *hyperparameter* wajib (A1–A5) serta dua faktor pilihan (fungsi loss B4 dan horizon B6) terhadap akurasi prediksi model di lokasi Duomo.
2) Menentukan kombinasi konfigurasi terbaik untuk masing-masing model berdasarkan metrik validasi MAE.
3) Menguji kemampuan generalisasi spasial model terbaik tanpa perubahan parameter pada karakteristik trafik lokal Parco Sempione.

II. Data dan Metode

A. Dataset

Laporan ini menggunakan dataset yang bersumber dari **Telecom Italia Big Data Challenge** [3], khususnya versi agregasi per jam (**hourly**) yang telah dipraproses oleh [4]. Data ini mencakup wilayah metropolitan kota Milan, Italia, dengan resolusi temporal berbasis per jam. Fitur-fitur utama yang tersedia di dalam dataset meliputi data trafik telekomunikasi seluler, yaitu panggilan keluar/masuk (*call*), pesan teks singkat (*sms*), serta aktivitas internet (*net*) yang menjadi target prediksi utama.

Eksperimen studi ablasi ini mengevaluasi dua lokasi spesifik di kota Milan:

1) **Kotak Duomo**: Merupakan area pusat kota acuan dengan kode grid **5060**. Data dari lokasi ini digunakan sebagai basis utama pengembangan model dari Bagian 0 hingga Bagian C.
2) **Parco Sempione (Lokasi Kelompok 6)**: Merupakan lokasi spesifik yang ditugaskan kepada kelompok kami dengan kode wilayah **6** dan nomor grid **5455**. Data dari Parco Sempione ini digunakan secara khusus pada Bagian D untuk menguji kemampuan generalisasi spasial dari konfigurasi model terbaik yang telah ditemukan di Duomo. visualisasi spasial dari seluruh titik evaluasi di kota Milan dapat dilihat pada Gambar 1.

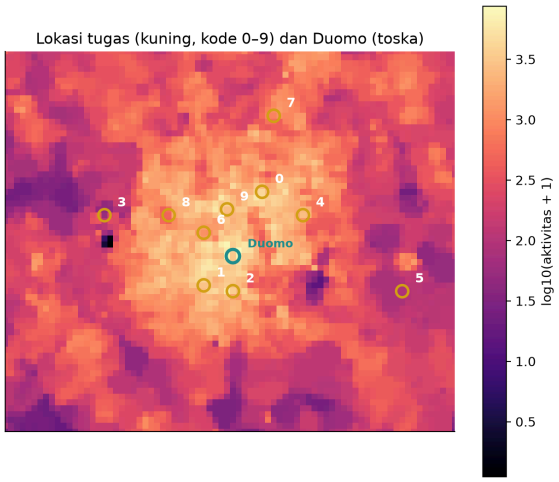


Fig. 1. Rata-rata aktivitas internet per kotak di Milan. Lingkaran kuning: lokasi tugas (kode 0–9); lingkaran toska: Duomo.

B. Pembagian Data dan Praproses

Dataset deret waktu dalam eksperimen ini dibagi menjadi empat periode non-overlapping berdasarkan urutan kronologis waktu:

1) **Train (Pelatihan)**: Berlangsung dari tanggal 11 November hingga 8 Desember 2013, yang digunakan sebagai basis utama model untuk mempelajari pola temporal trafik seluler.
2) **Validation (Validasi)**: Berlangsung dari tanggal 9 Desember hingga 15 Desemeber 2013, yang berfungsi sebagai acuan untuk studi ablasi, penyetelan *hyperparameter*, serta penentuan arsitektur terbaik.
3) **Test (Pengujian)**: Berlangsung dari tanggal 16 Desember hingga 22 Desember 2013 untuk evaluasi akhir performa model pada kondisi normal.
4) **Natal (Kondisi Khusus)**: Berlangsung dari tanggal 23 Desember hingga 29 Desember 2013 yang digunakan khusus untuk menguji ketahanan model terhadap anomali atau lonjakan trafik musiman pada hari libur besar.

Adapun data pada minggu pertama (4–10 November 2013) tidak masuk ke dalam set pelatihan, melainkan hanya dipertahankan sebagai konteks awal jendela histori temporal.

Sebelum pembentukan jendela data (*windowing*), tahap praproses dilakukan menggunakan teknik standarisasi nilai Z-score. Untuk mencegah terjadinya *data leakage* (kebocoran data), nilai rata-rata (*mean*) dan simpangan baku (*standard deviation*) dihitung secara ketat hanya menggunakan statistik data sebelum minggu validasi (data pelatihan). Nilai statistik ini kemudian digunakan untuk mentransformasikan seluruh partisi data ke skala yang seragam.

Proses pembuatan sampel data menggunakan teknik *sliding window* dengan panjang jendela W jam untuk memetakan histori fitur masa lalu menjadi representasi matriks X, yang digunakan untuk memprediksi target trafik y pada horizon H jam ke depan.

Dalam pemrosesan data deret waktu, data tidak boleh diacak (*shuffling*) sebelum proses *windowing* dilakukan. Hal ini dikarenakan data deret waktu memiliki dependensi temporal yang kuat, di mana urutan kronologis antar baris data membawa informasi penting mengenai tren dan musiman (seperti pola harian dan mingguan). Pengacakan urutan data akan merusak struktur hubungan sebab-akibat temporal tersebut, merusak fungsionalitas memori pada model rekuren, dan menyebabkan bias evaluasi akibat kebocoran informasi masa depan ke masa lalu.

C. Model dan Konfigurasi Acuan

Eksperimen ini mengevaluasi empat arsitektur jaringan saraf dengan karakteristik pemrosesan temporal yang berbeda untuk memprediksi trafik seluler:

1) **ANN (*Artificial Neural Network*)**: Model arsitektur maju (*feed-forward*) di mana seluruh fitur dalam dimensi jendela waktu ($W \times \text{fitur}$) diratakan menjadi satu vektor panjang. Hubungan temporal tidak diproses secara sekuensial, melainkan dipetakan sekaligus melalui lapisan tersembunyi linier berdensitas penuh (**Fully Connected Layers**).
2) **RNN (*Recurrent Neural Network*)**: Model sekuensial dasar yang memproses urutan jam demi jam menggunakan mekanisme umpan balik internal (*recurrent loop*). Informasi masa lalu disimpan dalam sebuah vektor **hidden state**, namun arsitektur ini rentan terhadap masalah hilangnya gradien (**vanishing gradient**) pada urutan jangka panjang.
3) **LSTM (*Long Short-Term Memory*)**: Pengembangan dari RNN yang mengatasi masalah **vanishing gradient** dengan memperkenalkan struktur sel memori terproteksi. Model ini memanfaatkan tiga gerbang (*gate*) internal—yaitu **input gate**, **forget gate**, dan **output gate**—untuk menyaring, menyimpan, atau membuang informasi jangka panjang secara adaptif.
4) **GRU (*Gated Recurrent Unit*)**: Variasi arsitektur rekuren yang lebih ringkas dibandingkan LSTM. GRU menyederhanakan mekanisme gerbang menjadi hanya dua komponen, yaitu **reset gate** dan **update gate**, serta menggabungkan sel memori langsung ke dalam **hidden state**, menjadikannya lebih efisien secara komputasi dengan performa yang kompetitif.

Konfigurasi acuan dasar yang digunakan sebagai titik awal studi ablasi dirancang agar jumlah parameter model rekuren setara secara adil (berada pada kisaran *pm* 5,5 ribu parameter). Parameter spesifik untuk pengujian acuan ini dirangkum dalam Tabel I.

D. Protokol Ablasi dan Evaluasi

Studi ablasi pada eksperimen ini mengikuti protokol isolasi parameter, di mana performa model dievaluasi dengan cara mengubah satu faktor eksperimen dalam satu waktu sementara parameter lainnya dipertahankan tetap sesuai dengan nilai acuan. Faktor eksperimen wajib yang diuji meliputi panjang jendela W (A1), ukuran *hidden units* (A2), jumlah lapisan (A3), *learning rate* (A4), dan kelompok fitur (A5). Selain faktor wajib tersebut, kelompok kami memilih dua faktor tambahan pada Bagian B untuk dianalisis lebih lanjut, yaitu:

TABLE I
KONFIGURASI ACUAN EKSPERIMEN

Hyperparameter	Nilai acuan
Panjang jendela W	24 jam
Horizon	1 jam
Ukuran hidden	ANN: 32, RNN: 68, LSTM: 33, GRU: 38 (Total parameter pm 5,5k)
Jumlah lapisan	ANN: 2 lapisan tersembunyi, Rekuren: 1 lapisan
Kelompok Fitur	semua (net, call, sms, jam_sin, jam_cos, hari_sin, hari_cos) [7 fitur]
Optimizer, *learning rate*	Adam, 10^{-3}
Batch size	64
Dropout	0.0
Fungsi loss	MSE Loss
Early stopping	*patience* 30, maksimum 300 epoch

1) **Fungsi Loss (B4)**: Menguji pengaruh fungsi loss **MSE**, **MAE**, dan **Huber** terhadap optimasi model. Hipotesis awal kami adalah penggunaan fungsi loss MAE akan menghasilkan nilai metrik evaluasi MAE yang paling rendah karena mengoptimalkan fungsi objektif yang sejalan dengan metrik target.
2) **Horizon Prediksi (B6)**: Mengevaluasi batas kemampuan peramalan model pada jangka waktu 1, 6, dan 24 jam ke depan. Hipotesis awal kami adalah performa model akan menurun drastis seiring bertambahnya jarak horizon prediksi, dan pada akhirnya akan kalah saing oleh *baseline* naif temporal pada pengujian jangka panjang (24 jam).

Untuk menjamin keandalan hasil dan mengantisipasi bias akibat inisialisasi bobot acak, setiap konfigurasi dilatih secara otomatis menggunakan 3 sandi acak (*seed*) yang berbeda $(0, 1, 2)$. Nilai performa yang dilaporkan pada hasil eksperimen merupakan nilai $(\text{rata-rata} \pm \text{simpangan baku})$.Evaluasi performa model dihitung menggunakan tiga metrik standar pada skala asli data trafik: *Mean Absolute Error* (MAE), *Root Mean Squared Error* (RMSE), dan *Mean Absolute Percentage Error* (MAPE).

Konfigurasi terbaik untuk masing-masing arsitektur dipilih secara ketat berdasarkan nilai rata-rata MAE terkecil pada set validasi untuk mencegah fenomena *overfitting* atau peninjauan data uji secara prematur (*data snooping*). Seluruh proses komputasi dan pelatihan model diselesaikan menggunakan perangkat keras berbasis **Central Processing Unit (CPU)** pada lingkungan kerja **PyTorch 2.15.0+cpu**. Total keseluruhan eksperimen mencakup 372 kali *training run* dengan akumulasi waktu komputasi selama **130.7 menit**.

III. HASIL

A. Baseline Naif dan Acuan

Evaluasi model diawali dengan menghitung performa dari tiga model *baseline* naif (tanpa proses pembelajaran) pada horizon 1 jam dan 24 jam untuk menjadi ambang batas performa minimum. Berdasarkan data pengujian di lokasi Duomo pada Tabel II, model *baseline* "Naif: minggu lalu" memberikan performa terbaik untuk prediksi jangka panjang (horizon 24 jam) pada set pengujian normal (*test*) dengan nilai MAE sebesar 466.1. Sebaliknya, tebakan berbasis nilai terakhir ("Naif: nilai terakhir") mengalami lonjakan eror yang sangat ekstrem saat diuji pada horizon 24 jam (MAE mencapai 2769.3) akibat sifat fluktuatif data trafik seluler.

TABLE II
PERFORMA METRIK MAE DARI BASELINE NAIF DI LOKASI DUOMO

Horizon	Model Baseline	Val	Test	Natal
1 jam	Naif: nilai terakhir	662.6	600.9	431.2
	Naif: kemarin	595.3	552.2	921.5
	Naif: minggu lalu	492.8	467.6	1426.2
24 jam	Naif: nilai terakhir	2750.4	2769.3	2052.0
	Naif: kemarin	618.4	563.4	915.1
	Naif: minggu lalu	493.5	466.1	1431.6

Setelah menetapkan batasan baseline, keempat arsitektur model dilatih menggunakan parameter acuan standar (Bagian 0) pada horizon 1 jam. Hasil rata-rata performa beserta simpangan baku dari 3 *seed* dirangkum dalam Tabel III.

Model berbasis rekuren terbukti jauh mengungguli arsitektur ANN konvensional. RNN meraih performa validasi terbaik dengan rata-rata MAE 206.1 ± 7.4, disusul sangat ketat oleh GRU dengan MAE 207.5 ± 3.8. Fenomena ini terjadi karena lapisan rekuren mampu mempertahankan representasi memori temporal sekuensial jam demi jam secara lebih efektif dibandingkan ANN yang meratakan seluruh dimensi waktu.

TABLE III
PERFORMA METRIK MAE KONFIGURASI ACUAN DI DUOMO (RATA-RATA ± SIMPANGAN BAKU)

Model	Total Param	Epoch Rata-rata	Val MAE	Test MAE
ANN	6.497	106.3	248.9 ± 8.9	309.9 ± 5.9
RNN	5.305	163.7	206.1 ± 7.4	229.6 ± 5.1
LSTM	5.578	168.7	230.5 ± 12.2	273.6 ± 25.4
GRU	5.397	193.7	207.5 ± 3.8	237.2 ± 9.3

B. Ablasi Wajib

a) *A1. Panjang Jendela (W):* Pengujian variasi panjang jendela $W \in \{6, 12, 24, 48, 168\}$ jam menunjukkan pola yang bertolak belakang antara model ANN dan model rekuren. Berdasarkan data eksperimen, jendela yang lebih panjang **tidak selalu lebih baik** untuk semua arsitektur.

Pada model ANN, penambahan panjang jendela menyebabkan jumlah parameter membengkak secara drastis (dari 2.465 parameter pada $W = 6$ menjadi 38.753 parameter pada $W = 168$). Lonjakan parameter ini menyebabkan ANN mengalami **overfitting** yang parah pada set data latih yang

kecil ini, ditandai dengan pemburukan nilai validasi MAE dari 212.4 ($W = 6$) menjadi 298.2 ($W = 168$).

Sebaliknya, jumlah parameter pada model rekuren (RNN, LSTM, GRU) bersifat konstan meskipun jendela waktu diperpanjang. Model rekuren, khususnya RNN, menunjukkan stabilitas yang sangat baik dengan performa terbaik pada $W = 48$ (Val MAE: 200.1 ± 5.3). Hal ini membuktikan bahwa mekanisme pemrosesan sekuensial jauh lebih efisien dalam mengekstrak histori jangka panjang tanpa membebani kapasitas memori model.

b) *A2. Ukuran Hidden:* Ukuran dimensi tersembunyi (**hidden units**) divariasikan pada nilai $\{16, 32, 64, 128\}$. Karena nilai yang sama diterapkan pada keempat model, jumlah parameter internal tidak lagi setara; sebagai contoh, pada **hidden** 128, LSTM membengkak hingga 70.273 parameter sedangkan RNN hanya 17.665 parameter.

Hasil eksperimen menunjukkan bahwa model yang lebih besar **cenderung memberikan hasil lebih baik** meskipun data latih terbatas. Peningkatan ukuran **hidden** dari 16 ke 128 berhasil menurunkan rata-rata validasi MAE pada seluruh model. Performa paling optimal diraih oleh GRU dengan **hidden** 128 yang mencatatkan Val MAE terendah sebesar 188.7 ± 4.2. Meskipun kapasitas model meningkat, mekanisme **early stopping** berhasil menjaga model agar tidak mengalami degradasi performa akibat **overfitting**.

c) *A3. Jumlah Lapisan:* Eksperimen penumpukan lapisan (**stacked layers**) dilakukan pada tingkatan $\{1, 2, 3\}$. Berdasarkan metrik rata-rata epoch, model yang lebih dalam terbukti **lebih cepat mengalami overfit**. Hal ini terlihat jelas dari penurunan jumlah epoch bertahan seiring bertambahnya lapisan (misalnya, RNN menurun dari 163.7 epoch pada 1 lapisan menjadi 96.0 epoch pada 3 lapisan).

Dari segi performa, menumpuk lapisan rekuren justru **memperburuk** akurasi prediksi. Model LSTM merupakan yang paling sensitif, di mana penambahan menjadi 3 lapisan menyebabkan Val MAE melonjak drastis dari 230.5 menjadi 338.9 dengan tingkat ketidakstabilan antar-*seed* yang sangat tinggi ($\pm$16.9). Jaringan yang terlalu dalam pada data temporal pendek ini membuat ruang pencarian parameter menjadi terlalu kompleks dan memicu hilangnya gradien.

d) *A4. Learning Rate (`lr`):* Pengujian dilakukan pada nilai `lr` $\in \{0.0001, 0.001, 0.01\}$. Pada nilai **learning rate** yang terlalu kecil (0.0001), proses optimasi berjalan sangat lambat sehingga seluruh model terhenti secara prematur karena menyentuh batas maksimum `max_epochs` (300 epoch) sebelum konvergen. Akibatnya, eror validasi membengkak hingga mendekati kisaran $pm400$ MAE pada LSTM dan GRU.

Pada **learning rate** besar (0.01), model rekuren mampu berkonvergen lebih cepat dengan jumlah epoch yang jauh lebih sedikit. Namun, nilai `lr` yang tinggi meningkatkan risiko ketidakstabilan fluktuasi gradien saat mendekati minimum lokal, yang ditandai dengan tingginya nilai simpangan baku antar-*seed* (seperti terlihat pada LSTM dengan tingkat ketidakpastian sebesar $\pm$14.2). Nilai acuan 0.001 terbukti menjadi titik kompromi paling stabil bagi mayoritas model.

e) *A5. Kelompok Fitur:* Faktor terakhir mengevaluasi empat kombinasi masukan: `net`, `net+call+sms`, `net+waktu`, dan `semua`. Hasil eksperimen menunjukkan bahwa **informasi waktu (jam & hari) jauh lebih berguna** daripada riwayat trafik telepon/SMS. Penggunaan fitur `net+waktu` terbukti mengungguli fitur `net+call+sms` secara signifikan pada seluruh arsitektur.

TABLE IV
PENGARUH PANJANG JENDELA W TERHADAP VALIDASI MAE DI DUOMO (RATA-RATA $\pm$ SIMPANGAN BAKU, 3 SEED). NILAI TERBAIK DICETAK TEBAL.

W (jam)	ANN	RNN	LSTM	GRU
6	212.4 ± 5.3	215.5 ± 4.1	227.1 ± 4.3	212.6 ± 11.5
12	238.5 ± 4.5	206.7 ± 6.2	235.6 ± 2.0	208.9 ± 10.4
24	248.9 ± 8.9	206.1 ± 7.4	230.5 ± 12.2	207.5 ± 3.8
48	261.7 ± 2.8	$\mathbf{200.1 \pm 5.3}$	249.1 ± 21.8	206.7 ± 5.0
168	298.2 ± 18.2	204.8 ± 10.2	241.4 ± 8.1	$\mathbf{206.7 \pm 5.1}$

TABLE V
PENGARUH FUNGSI LOSS TERHADAP VALIDASI MAE DI DUOMO (RATA-RATA $\pm$ SIMPANGAN BAKU, 3 SEED).

Fungsi Loss	ANN	RNN	LSTM	GRU
mse	248.9 ± 8.9	206.1 ± 7.4	230.5 ± 12.2	207.5 ± 3.8
mae	$\mathbf{240.6 \pm 7.1}$	219.2 ± 10.1	234.5 ± 11.9	$\mathbf{204.2 \pm 4.8}$
huber	241.9 ± 3.7	206.3 ± 10.0	233.6 ± 13.6	207.8 ± 5.1

Model rekuren terlihat sangat membutuhkan penyertaan fitur waktu secara eksplisit dibandingkan ANN. Ketika hanya diberikan fitur tunggal `net`, performa model rekuren memburuk tajam (GRU naik dari MAE 207.5 menjadi 264.6). Hal ini disebabkan karena model rekuren membaca urutan secara monoton jam demi jam; tanpa adanya fitur siklus waktu (`jam_sin`/`jam_cos`), model rekuren kesulitan menangani lompatan pola musiman harian (*diurnal cycle*) yang esensial pada data trafik telekomunikasi. Pilihan kelompok fitur `semua` memberikan performa terbaik karena menyediakan representasi konteks temporal yang lengkap.

C. Ablasi Pilihan

a) *B4. Fungsi Loss:* Pengujian fungsi loss **MSE**, **MAE**, dan **Huber** menunjukkan bahwa loss MAE berhasil menurunkan nilai metrik validasi MAE secara konsisten pada arsitektur ANN dan GRU (Tabel V). Hal ini sesuai dengan hipotesis awal karena fungsi objektif MAE melatih bobot model secara langsung untuk meminimalkan penyimpangan absolut skala asli data trafik. Performa paling optimal dicatatkan oleh GRU dengan nilai MAE sebesar 204.2 ± 4.8.

b) *B6. Horizon Prediksi (H):* Evaluasi pada jarak peramalan $Hin\{1, 6, 24\}$ jam membuktikan hipotesis awal bahwa akurasi model menurun drastis seiring bertambahnya

TABLE VI
PENGARUH HORIZON PREDIKSI H TERHADAP VALIDASI MAE DI DUOMO (RATA-RATA ± SIMPANGAN BAKU, 3 SEED).

Horizon	ANN	RNN	LSTM	GRU
1 jam	248.9 ± 8.9	206.1 ± 7.4	230.5 ± 12.2	207.5 ± 3.8
6 jam	337.2 ± 2.4	416.6 ± 11.4	392.9 ± 24.5	381.1 ± 21.0
24 jam	449.0 ± 7.6	437.2 ± 3.2	456.9 ± 19.8	451.8 ± 11.6

TABLE VII
PERBANDINGAN PERFORMA ACUAN VS TERBAIK PADA MINGGU TEST DAN NATAL DI DUOMO (RATA-RATA ± SIMPANGAN BAKU).

Model & Konfigurasi	Total Param	Val MAE	Test MAE	Natal MAE
ANN Acuan	6.497	248.9 ± 8.9	309.9 ± 5.9	680.1 ± 52.0
ANN Terbaik	5.297	238.8 ± 12.8	$\mathbf{293.6 \pm 21.3}$	$\mathbf{639.2 \pm 62.4}$
RNN Acuan	5.305	206.1 ± 7.4	229.6 ± 5.1	$\mathbf{421.2 \pm 2.4}$
RNN Terbaik	5.021	209.4 ± 11.8	238.6 ± 17.2	427.1 ± 34.7
LSTM Acuan	5.578	230.5 ± 12.2	273.6 ± 25.4	586.0 ± 56.8
LSTM Terbaik	37.925	225.5 ± 13.4	$\mathbf{258.9 \pm 25.5}$	$\mathbf{542.2 \pm 60.2}$
GRU Acuan	5.397	207.5 ± 3.8	207.5 ± 3.8	$\mathbf{468.2 \pm 21.8}$
GRU Terbaik	78.603	216.3 ± 10.8	$\mathbf{233.8 \pm 15.7}$	483.5 ± 36.1

horizon akibat tingginya ketidakpastian trafik di masa depan (Tabel VI).

Pada horizon jangka panjang (24 jam), performa seluruh model memburuk hingga kisaran *pm*440 MAE. Pada titik ini, model deep learning mulai **kalah saing** dari baseline "Naif: minggu lalu" (Val MAE: 493.5). Hal ini membuktikan batas saturasi model sekuensial, di mana pola musiman mingguan yang berulang jauh lebih andal digunakan sebagai tebakan langsung untuk peramalan jangka panjang.

D. Konfigurasi Terbaik

Berdasarkan rata-rata MAE set validasi, konfigurasi parameter terbaik gabungan untuk masing-masing arsitektur model ditentukan sebagai berikut:

- **ANN**: $W = 6$, *hidden*=128, *layers*=1, `lr` $= 0.001$, fitur=`net+waktu`, *loss*=`mae`.
- **RNN**: $W = 48$, *hidden*=64, *layers*=1, `lr` $= 0.001$, fitur=`semua`, *loss*=`mse`.
- **LSTM**: $W = 6$, *hidden*=128, *layers*=1, `lr` $= 0.01$, fitur=`semua`, *loss*=`mse`.
- **GRU**: $W = 48$, *hidden*=128, *layers*=2, `lr` $= 0.001$, fitur=`semua`, *loss*=`mae`.

Perbandingan hasil evaluasi akhir pada minggu Test dan Natal dirangkum dalam Tabel VII.

Hasil menunjukkan bahwa penggabungan parameter terbaik individu **tidak otomatis meningkatkan akurasi secara bersamaan**. Model ANN dan LSTM sukses memperbaiki performa uji secara signifikan. GRU Terbaik meraih eror paling optimal pada minggu Test (233.8), namun sedikit memburuk pada minggu Natal.

Sebaliknya, model RNN terbaik justru mengalami degradasi performa dibanding versi acuan (Test MAE naik ke 238.6). Hal ini menjustifikasi adanya interaksi negatif antar-faktor ($W = 48$ dan *hidden*=64) yang merusak ruang optimal parameter. Seluruh arsitektur mengalami lonjakan eror hingga dua kali lipat pada minggu Natal akibat ketidakmampuan model dalam menangani anomali ekstrem mobilitas libur akhir tahun.

TABLE VIII
HASIL GENERALISASI ACUAN VS TERBAIK DI PARCO SEMPIONE (RATA-RATA ± SIMPANGAN BAKU).

Model & Konfigurasi	Val MAE	Test MAE	Test MAPE	Natal MAE
ANN Acuan	113.2 ± 5.7	117.8 ± 3.6	11.5 ± 0.4	243.4 ± 25.2
ANN Terbaik	109.4 ± 5.4	108.6 ± 10.9	10.7 ± 1.0	244.9 ± 21.4
RNN Acuan	104.2 ± 1.5	$\mathbf{99.5 \pm 2.7}$	10.0 ± 0.4	$\mathbf{185.3 \pm 13.8}$
RNN Terbaik	105.3 ± 3.7	99.7 ± 3.3	10.0 ± 0.5	184.1 ± 9.5
LSTM Acuan	121.3 ± 14.7	119.8 ± 19.2	12.0 ± 2.8	309.6 ± 55.3
LSTM Terbaik	113.7 ± 12.5	108.9 ± 17.2	10.6 ± 2.4	284.5 ± 46.2
GRU Acuan	107.2 ± 3.8	108.4 ± 8.9	10.9 ± 0.9	217.4 ± 28.3
GRU Terbaik	107.1 ± 3.0	105.6 ± 7.7	10.6 ± 0.8	231.8 ± 28.0

E. Uji Generalisasi

Konfigurasi acuan dan terbaik diuji ulang pada lokasi kelompok yaitu **Parco Sempione (Lokasi 6)** untuk mengukur kemampuan generalisasi spasial model. Karakteristik fluktuasi dan volume trafik di Parco Sempione jauh lebih rendah dibandingkan pusat kota Duomo. Perbandingan performa akhir dirangkum dalam Tabel VIII.

Hasil eksperimen menunjukkan bahwa urutan model terbaik di Parco Sempione **mengalami perubahan** dibanding Duomo. Di lokasi ini, RNN Acuan menjadi model paling optimal dengan Test MAE terkecil (99.5 ± 2.7).

Konfigurasi terbaik hasil optimasi Duomo tetap mampu mengungguli versi acuannya pada model ANN, LSTM, dan GRU di lokasi baru ini. Namun, seluruh model deep learning masih kalah saing terhadap model baseline "Naif: nilai terakhir" pada minggu Natal lokal yang mencatatkan eror MAE sebesar 77.6. Hal ini membuktikan bahwa konfigurasi terbaik yang ditala di satu lokasi padat (Duomo) tidak sepenuhnya adaptif terhadap karakteristik anomali lokal di area publik terbuka seperti Parco Sempione selama masa libur panjang.

IV. Pembahasan

Berdasarkan seluruh rangkaian eksperimen, *hyperparameter* yang paling berpengaruh secara signifikan terhadap performa model adalah **learning rate** (`lr`) dan **panjang jendela** (W). Nilai `lr` yang terlalu kecil (0.0001) menggagalkan konvergensi karena menyentuh batas maksimum epoch, sedangkan jendela W yang terlalu panjang (168 jam) memicu pembengkakan parameter dan **overfitting** yang parah pada arsitektur non-sekuensial (ANN).

Perbedaan hasil antar-arsitektur model terbukti jauh lebih besar dan menentukan dibandingkan variasi fluktuasi acak antar-*seed*, menegaskan bahwa pemilihan struktur fundamental jaringan (seperti penambahan gerbang rekuren pada LSTM/GRU) memegang peran krusial dalam keberhasilan ekstraksi fitur temporal.

Keterbatasan utama dalam studi ablasi ini meliputi pemanfaatan basis data latih yang sangat terbatas (672 sampel train atau setara 4 minggu) serta evaluasi yang berpusat pada satu kluster geografis kota. Hal ini menyebabkan konfigurasi terbaik yang telah ditala secara optimal di pusat kota padat (Duomo) mengalami penurunan adaptasi dan saturasi saat digeneralisasikan ke lokasi ruang publik terbuka dengan volume trafik rendah seperti Parco Sempione, terutama dalam mengantisipasi anomali mobilitas pada libur Natal.

V. Kesimpulan

Studi ablasi ini berhasil mengevaluasi pengaruh variasi arsitektur dan *hyperparameter* untuk prediksi trafik seluler di kota Milan. Model berbasis rekuren (RNN dan GRU) terbukti jauh lebih efisien dan unggul dalam mempertahankan memori urutan waktu harian dibandingkan arsitektur ANN konvensional.

Optimasi parameter gabungan pada lokasi Duomo berhasil menempatkan GRU Terbaik sebagai model dengan akurasi paling optimal pada minggu normal dengan nilai Test MAE sebesar 233.8 ± 15.7. Namun, pengujian generalisasi spasial di Parco Sempione menunjukkan perubahan tren, di mana arsitektur RNN dasar justru meraih performa terbaik dengan eror Test MAE terkecil mencapai 99.5 ± 2.7. Nilai eror prediksi pada momen musiman khusus (Natal) melonjak hingga dua kali lipat pada seluruh model, membuktikan perlunya integrasi fitur eksternal musiman untuk meningkatkan ketahanan peramalan jangka panjang.

Kontribusi Anggota

Tyodonrau	Menyusun bagian Pendahuluan, bab Metodologi (Dataset & Praproses), serta melakukan integrasi dan perapian teks pada template Typst.
Adryan	Menjalankan eksperimen kode, mengumpulkan data angka riil studi ablasi wajib (A1–A5), serta menulis draf analisis Hasil Ablasi Wajib.
Joan	Menjalankan eksperimen faktor pilihan (B4 & B6), menganalisis data Bagian C & D (Parco Sempione), serta menulis bab Pembahasan dan Kesimpulan.

Pernyataan Penggunaan AI

Penulis menggunakan perangkat AI seperti ChatGPT dan Gemini untuk membantu memvalidasi struktur kode eksperimen serta memperbaiki tata bahasa laporan agar lebih rapi dan sistematis.

Kode dan Data

Kode, notebook beserta output, dan seluruh hasil run tersedia di https://github.com/Bufel/dlw-tugas-rb-124400052.

Pustaka

[1] S. Hochreiter and J. Schmidhuber, "Long Short-Term Memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997, doi: 10.1162/neco.1997.9.8.1735.

[2] K. Cho *et al.*, "Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation," in *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2014, pp. 1724–1734. doi: 10.3115/v1/D14-1179.

[3] G. Barlacchi *et al.*, "A multi-source dataset of urban life in the city of Milan and the Province of Trentino," *Scientific Data*, vol. 2, p. 150055, 2015, doi: 10.1038/sdata.2015.55.

[4] C. Zhang, S. Dang, B. Shihada, and M.-S. Alouini, "Dual Attention-Based Federated Learning for Wireless Traffic Prediction," in *IEEE INFOCOM 2021 – IEEE Conference on Computer Communications*, 2021, pp. 1–10. doi: 10.1109/INFOCOM42981.2021.9488883.